

Machine Learning 机器学习

目录

1 线性回归模型	4
1.1 线性回归模型的建立	4
1.2 模型求解	5
1.2.1 利用最小二乘法求解	5
1.2.2 利用最大似然估计求解	7
1.3 线性回归模型的推广	8
1.3.1 广义线性模型 (Generalized Linear Model)	8
1.3.2 广义加性模型 (Generalized Additive Model)	8
2 线性分类模型	9
2.1 线性二分类模型的建立	9
2.1.1 激活函数的选取	9
2.1.2 模型的建立	9
2.2 模型求解	10
2.2.1 利用最小二乘法求解	10
2.3 线性多分类模型	11
3 多层感知机	12
3.1 基本思路	12
3.2 前向传播	12
3.3 反向传播	12
4 支持向量机	14
4.1 空间向量基础知识	14
4.1.1 超平面	14
4.1.2 点到超平面的距离	15
4.2 线性支持向量机	15
4.2.1 优化问题	15
4.2.2 对偶问题	17
4.2.3 模型求解与结果	18
4.2.4 线性支持向量机分类器的分析	20
4.2.5 软间隔支持向量机	20

4.3 非线性支持向量机	23
4.3.1 非线性支持向量机的优化问题与求解	23
4.3.2 常用核函数	24
5 线性分类器的损失函数及其优化函数	24
5.1 常见线性分类器的损失函数	24
5.1.1 支持向量机的损失函数	24
5.1.2 logistics 回归的损失函数	25
5.1.3 常见损失函数总结	26
5.2 线性分类器的优化函数一般形式	26
5.2.1 常见优化函数总结	27
6 训练方法与技巧	28
6.1 梯度下降法	28
6.2 动量梯度下降法	28
6.3 RMSProp	28
6.4 Adam	28
7 卷积神经网络	29
8 聚类分析	29
8.1 K-Means	30
8.1.1 问题定义	30
8.1.2 算法思想	31
8.1.3 算法流程	31
9 隐变量模型	31
9.1 隐变量模型的训练	32
9.2 高斯混合模型	32
9.3 EM 算法	34
9.3.1 理论保证	35
9.3.2 EM 算法总结	37
9.4 EM 算法训练高斯混合模型	38
9.4.1 E step	38
9.4.2 M step	40
9.4.3 GMM 的 EM 算法总结	41

10 图表的插入	42
10.1 表格的插入	42
10.2 图的插入	43
A 附录 文件列表	44
B 附录 代码	44

1 线性回归模型

1.1 线性回归模型的建立

最简单的线性回归模型是输入变量的线性组合。线性回归模型是利用输入变量的线性组合拟合样本数据。

假设一个样本数据 $(\mathbf{x}, y)$, 其中 $\mathbf{x}$ 共有 n 个属性, 即有 n 个维度, 即 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$, $x_i \in \mathbb{R}$, $i = 1, 2, \dots, n$, 它所对应的输出变量为 y 。

线性回归模型是一个线性函数

$$f(\mathbf{x}, \mathbf{w}, b) = b + w_1x_1 + \dots + w_nx_n \quad (1.1)$$

其中, b 是线性函数的截距, $\mathbf{w} = (w_1, \dots, w_n)^T$

下面将式 (1.1) 写成紧凑的矩阵形式,

$$f(\mathbf{x}, \mathbf{w}, b) = b + \mathbf{x}^T \mathbf{w} \quad (1.2)$$

为了得到更加统一的形式, 令式 (1.1) 中的 $b = w_0$ 则有

$$f(\mathbf{x}, \mathbf{w}) = w_0 + w_1x_1 + \dots + w_nx_n \quad (1.3)$$

在之后的推导中, 若无特殊说明, 都会使用 w_0 来表示截距, 而不用 b 来表示。

假设 $\tilde{\mathbf{x}} = (1, x_1, x_2, \dots, x_n)^T$, $\mathbf{w} = (w_0, w_1, \dots, w_n)^T$, 则式 (1.3) 可以写为

$$f(\tilde{\mathbf{x}}, \mathbf{w}) = \tilde{\mathbf{x}}^T \mathbf{w} \quad (1.4)$$

在这里, 我将 $\tilde{\mathbf{x}}$ 称为增广的样本输入 (向量)。

注意:

1. 式 (1.4) 中的 $\tilde{\mathbf{x}}$ 比式 (1.2) 中的 $\mathbf{x}$ 多了一个 1
2. 此时的 y 仍然是一个标量。

用 $\hat{y}$ 表示模型的预测值, 那么线性回归模型的预测值就是模型的输出:

$$\hat{y} = f(\tilde{\mathbf{x}}, \mathbf{w}) \quad (1.5)$$

不可避免地, 样本数据的观测值与模型的预测值之间存在误差, 一般认为这个误差服从均值为 0 的正态分布。因此, 样本数据的观测值与模型的预测值之间的关系为

$$y = \hat{y} + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2) \quad (1.6)$$

将式 (1.5) 代入式 (1.6), 可得样本数据的观测值与样本输入之间的关系

$$y = f(\tilde{\mathbf{x}}, \mathbf{w}) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2) \quad (1.7)$$

1.2 模型求解

在求解模型时，考虑在实际情况下，我们有一个含有 m 个样本的样本数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ 。

模型的求解本质上是根据已有的样本数据集，求解出模型的参数下面使用 2 种方法分别求解线性回归模型，即求解模型参数 $\mathbf{w}$ 。

1.2.1 利用最小二乘法求解

最小二乘法 (Least square method) 本质上是要求预测值与观测值（真实值）尽可能地接近。

假设利用模型预测得到的预测值分别为 $\hat{y}_i$, ($i = 1, 2, \dots, m$), 为了衡量预测值与观测值之间的接近程度，采用均方误差 (Mean Square Error, MSE) 作为损失函数 (Loss function)

$$L(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 \quad (1.8)$$

将式 (1.5) 代入 (1.8)，得到：

$$L(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m (f(\tilde{\mathbf{x}}_i, \mathbf{w}) - y_i)^2 \quad (1.9)$$

通过最小化均方误差以使得预测值与观测值尽可能接近，由此可以写出以下优化问题

$$\min_{\mathbf{w}} L(\mathbf{w}) = \min_{\mathbf{w}} \frac{1}{m} \sum_{i=1}^m [f(\tilde{\mathbf{x}}_i, \mathbf{w}) - y_i]^2 \quad (1.10)$$

对于线性回归模型，将式 (1.4) 代入 (1.9)，得到：

$$L(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m (\tilde{\mathbf{x}}_i^T \mathbf{w} - y_i)^2 \quad (1.11)$$

通过最小化函数 $L(\mathbf{w})$, 即可求解出模型的最优参数 $\mathbf{w}$ 。

下面进一步将 (1.11) 写成更紧凑的矩阵形式，更加便于求解。

在样本数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ 中，记增广的样本输入向量

$$\tilde{\mathbf{x}}_i = \begin{bmatrix} 1 \\ \mathbf{x}_i \end{bmatrix} = \begin{bmatrix} 1 \\ x_{i1} \\ x_{i2} \\ \vdots \\ x_{in} \end{bmatrix}$$

然后将每个观测值 y_i 与其增广的样本输入向量 $\tilde{\mathbf{x}}_i$ 按照式 (1.7) 写出

$$\begin{cases} y_1 = f(\tilde{\mathbf{x}}_1, \mathbf{w}) + \varepsilon_1, \\ y_2 = f(\tilde{\mathbf{x}}_2, \mathbf{w}) + \varepsilon_2, \\ \vdots \\ y_m = f(\tilde{\mathbf{x}}_m, \mathbf{w}) + \varepsilon_m \end{cases} \quad (1.12)$$

对于线性回归模型, 将式 (1.4) 代入式 (1.12), 得到

$$\begin{cases} y_1 = \tilde{\mathbf{x}}_1^T \mathbf{w} + \varepsilon_1 = w_0 + x_{11}w_1 + x_{12}w_2 + \cdots + x_{1n}w_n + \varepsilon_1 \\ y_2 = \tilde{\mathbf{x}}_2^T \mathbf{w} + \varepsilon_2 = w_0 + x_{21}w_1 + x_{22}w_2 + \cdots + x_{2n}w_n + \varepsilon_2 \\ \vdots \\ y_m = \tilde{\mathbf{x}}_m^T \mathbf{w} + \varepsilon_m = w_0 + x_{m1}w_1 + x_{m2}w_2 + \cdots + x_{mn}w_n + \varepsilon_m \end{cases} \quad (1.13)$$

记

$$\mathbf{X} = \begin{bmatrix} \tilde{\mathbf{x}}_1^T \\ \tilde{\mathbf{x}}_2^T \\ \vdots \\ \tilde{\mathbf{x}}_m^T \end{bmatrix} = \begin{bmatrix} 1 & \mathbf{x}_1^T \\ 1 & \mathbf{x}_2^T \\ \vdots & \vdots \\ 1 & \mathbf{x}_m^T \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1n} \\ 1 & x_{21} & x_{22} & \cdots & x_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m1} & x_{m2} & \cdots & x_{mn} \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{bmatrix}$$

则式 (1.13) 可以写为更紧凑的矩阵形式

$$\mathbf{y} = \mathbf{X}\mathbf{w} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \Sigma^2) \quad (1.14)$$

那么均方误差损失函数即为

$$L(\mathbf{w}) = \frac{1}{m} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \quad (1.15)$$

注解:

式 (1.15) 是式 (1.11) 的二次型形式, 因此二式其实等价。

通过最小化损失函数 $L(\mathbf{w})$

$$\min_{\mathbf{w}} L(\mathbf{w}) = \frac{1}{m} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \quad (1.16)$$

即可求得线性回归模型的最优参数 $\mathbf{w}$ 。

对 (1.15) 求导, 得:

$$\begin{aligned} \frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} &= \frac{\partial}{\partial \mathbf{w}} \frac{1}{m} (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \\ &= \frac{2}{m} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) \end{aligned} \quad (1.17)$$

令导数为 0

$$\frac{2}{m} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = 0 \quad (1.18)$$

移项得:

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y} \quad (1.19)$$

假如 $\mathbf{X}^T \mathbf{X}$ 是可逆矩阵, 则可以得到 $\mathbf{w}$ 解析解

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (1.20)$$

最终, 求解得到的线性回归模型为

$$\hat{\mathbf{y}} = \tilde{\mathbf{x}}^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (1.21)$$

缺点:

1. $\mathbf{X}^T \mathbf{X}$ 的逆不一定存在。
2. 当矩阵维度特别大时, 求逆耗时大。

使用梯度下降法求解可以避免以上问题:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \left. \frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} \right|_{\mathbf{w}=\mathbf{w}_t} \quad (1.22)$$

代入式 (1.17), 得

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \frac{2}{m} \mathbf{X}^T (\mathbf{X}\mathbf{w}_t - \mathbf{y}) \quad (1.23)$$

1.2.2 利用最大似然估计求解

最大似然估计的核心思想是通过概率建模, 令样本观测值发生的概率最大。

设随机变量 $Y (Y \in \mathbb{R} \text{ 是一个标量})$,

$$Y = f(\tilde{\mathbf{x}}, \mathbf{w}) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

所以

$$Y - f(\tilde{\mathbf{x}}, \mathbf{w}) = \varepsilon \sim N(0, \sigma^2)$$

从而得到随机变量 Y 的分布

$$Y \sim N(f(\tilde{\mathbf{x}}, \mathbf{w}), \sigma^2) \quad (1.24)$$

Y 有观测值: $Y_1, Y_2, \dots, Y_m$, 假设它们之间独立同分布。那么 $Y_1 = y_1, Y_2 = y_2, \dots, Y_m =$

y_m 的概率为

$$\begin{aligned}
& P(Y_1 = y_1, Y_2 = y_2, \dots, Y_m = y_m) \\
&= P(Y_1 = y_1)P(Y_2 = y_2) \dots P(Y_m = y_m) \\
&= \prod_{i=1}^m P(Y_i = y_i) \\
&= \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - f(\mathbf{x}_i, \mathbf{w}))^2}{2\sigma^2}}
\end{aligned} \tag{1.25}$$

根据最大似然的定义（令样本数据发生的可能性最大），上式即为最大似然函数 (maximum likelihood function) $L(\mathbf{w})$

$$L(\mathbf{w}) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - f(\mathbf{x}_i, \mathbf{w}))^2}{2\sigma^2}} \tag{1.26}$$

对于线性回归模型，将式 (1.4) 代入式 (1.26)，可得

$$L(\mathbf{w}) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \mathbf{x}_i^T \mathbf{w})^2}{2\sigma^2}} \tag{1.27}$$

两边取对数，得

$$\ln L(\mathbf{w}) = - \sum_{i=1}^m \frac{(y_i - \mathbf{x}_i^T \mathbf{w})^2}{2\sigma^2} - \frac{m}{2} \ln(2\pi\sigma^2) \tag{1.28}$$

通过令式 (1.28) 最大化，求解出取得最大值时的 $\mathbf{w}$ 即为模型的最优参数

可以发现，式 (1.28) 中， $2\sigma^2$ 和 $\frac{m}{2} \ln(2\pi\sigma^2)$ 都是常数，不会影响优化问题的结果。因此，最小化函数 (1.11) 与最大化函数 (1.28) 其实是等价的。

1.3 线性回归模型的推广

1.3.1 广义线性模型 (Generalized Linear Model)

式 (1.5) 等号左边是输出变量的预测值 $\hat{y}$ 本身，将其推广为单调可微函数 $g(\hat{y})$ ，就是广义线性模型 (Generalized Linear Model, GLM)

$$g(\hat{y}) = w_0 + w_1 x_1 + \dots + w_n x_n \tag{1.29}$$

1.3.2 广义加性模型 (Generalized Additive Model)

定义基函数 $\phi(\mathbf{x})$ 是关于输入变量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 的非线性函数。

式 (1.3) 等号右边是输入变量 $x_1, x_2, \dots, x_n$ 的线性组合，我们将其推广为输入变量的函数 $\phi_j(\mathbf{x})$, ($j = 0, 1, 2, \dots, n$) 的线性组合，就是广义加性模型 (Generalized Additive Model, GAM) 特别地， $\phi_0 = 1$

$$f(\phi, \mathbf{w}) = w_0 + w_1\phi_1(\mathbf{x}) + \cdots + w_n\phi_n(\mathbf{x}) \quad (1.30)$$

记 $\phi = (\phi_0, \phi_1, \dots, \phi_n)^T$ 则 (1.30) 可以写为

$$f(\phi, \mathbf{w}) = \mathbf{w}^T \phi \quad (1.31)$$

求解方法与普通的线性回归模型相同。

2 线性分类模型

线性分类模型根据所分得类别的数量，可以分为二分类模型与多分类模型。

2.1 线性二分类模型的建立

2.1.1 激活函数的选取

!!! Todo: 这部分的逻辑有问题!!!

在二分类问题中，对于一个样本数据 $(\mathbf{x}, y)$ ，输出变量 y 不再是一个连续值，而是表示类别，即

$$\begin{cases} y = 0, & \text{if } \mathbf{x} \in \mathcal{C}_1 \\ y = 1, & \text{if } \mathbf{x} \in \mathcal{C}_2 \end{cases} \quad (2.1)$$

显然，能够满足以上要求的函数是单位阶跃函数

$$u(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

可是这个函数在 $x=0$ 处不可微，不便于求导等数学分析工具的使用。因此，考虑与 $u(x)$ 图像相似，但在实数轴上处处连续可微的 sigmoid 函数

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

2.1.2 模型的建立

在式 (1.4) 中， $\hat{\mathbf{x}}^T \mathbf{w}$ 得到的是一个在 $\mathbb{R}$ 上的连续值，对于回归任务，这是合适的。而对于分类任务，需要的是 0 或 1 的离散值，因此考虑使用单位阶跃函数将 $\mathbb{R}$ 上的连续值映射到为 0 或 1 的离散值，经过前文的讨论，单位阶跃函数不可微，不便于数学分析，使用 sigmoid 函数既方便数学分析，又可以把 $\mathbb{R}$ 上的连续值大部分映射到接近 0 或者接近 1 的值，当然也有部分值被映射到 $(0, 1)$ 中间。




图 1 单位阶跃函数与 **sigmoid** 函数

将 $\tilde{\mathbf{x}}^T \mathbf{w}$ 经 sigmoid 函数映射后，得到

$$f(\tilde{\mathbf{x}}, \mathbf{w}) = \sigma(\tilde{\mathbf{x}}^T \mathbf{w}) \quad (2.2)$$

即

$$f(\tilde{\mathbf{x}}, \mathbf{w}) = \frac{1}{1 + e^{-\tilde{\mathbf{x}}^T \mathbf{w}}} \quad (2.3)$$

这便是 **logistics** 回归模型。

因此，模型的预测值 $\hat{y}$ 为

$$\hat{y} = \frac{1}{1 + e^{-\tilde{\mathbf{x}}^T \mathbf{w}}} \quad (2.4)$$

对 (2.3) 作 Logit 变换，即

$$\text{logit}(\hat{y}) = \ln \frac{\hat{y}}{1 - \hat{y}}$$

得到

$$\ln \frac{\hat{y}}{1 - \hat{y}} = \tilde{\mathbf{x}}^T \mathbf{w} \quad (2.5)$$

这是 **logistics** 回归模型的另一种等价形式，可以视为 $g(\hat{y}) = \ln \frac{\hat{y}}{1 - \hat{y}}$ 时的广义线性模型，见式 (1.29)

2.2 模型求解

2.2.1 利用最小二乘法求解

$$\ln \frac{\hat{y}}{1 - \hat{y}} = \tilde{\mathbf{x}}^T \mathbf{w} \quad (2.6)$$

2.3 线性多分类模型

线性多分类模型，也被称为（单层）感知机模型。对于一个样本集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ ，共分成 K 类 $(\mathcal{C}_1, \dots, \mathcal{C}_K)$ ，其中 $\mathbf{x}_i \in \mathbb{R}, y_i (i = 1, 2, \dots, m)$ 是类别标签。

记独热向量为

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_K = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

对于 $\forall i, i = 1, 2, \dots, m$ ，若 $\mathbf{x}_i$ 属于第 k 类，则 y_i 用独热向量表示为：

$$y_i = \mathbf{e}_k, \quad \text{if } \mathbf{x}_i \in \mathcal{C}_k$$

通过线性变换

$$\mathbf{z} = w^T \mathbf{x} + \mathbf{b} \quad (2.7)$$

其中，样本点 $\mathbf{x} \in \mathbb{R}^n$ ，权重矩阵 $w \in \mathbb{R}^{n \times K}$ ，偏移 $\mathbf{b} \in \mathbb{R}^K$ ，线性变换后得到 $\mathbf{z} \in \mathbb{R}^K$

例如：若 $K = 4$ ，可能得到 $\mathbf{z} = [2, 5, -1, 0]^T$ 这 4 个分量分别代表了样本 $\mathbf{x}$ 在 4 个分类中的数值。

对 $\mathbf{z}$ 的所有分量取最大值 $\max$ ，得到最大分量所在的分量位置 j 就是样本所属的分类索引，即

$$j = \arg \max_j z_j$$

从而可以将预测值 $\hat{y}$ 表示为独热向量

$$\hat{y} = \mathbf{e}_j \quad (2.8)$$

延续前面的例子， $\mathbf{z} = [2, 5, -1, 0]^T$ 的最大分量为 5，它是第 2 个分量，则 $j = 2$ 故 $\hat{y} = [0, 1, 0, 0]^T$

但是， $\max$ 函数并不连续可微，因此，使用 softmax 函数对 $\max$ 函数进行近似，既能保留大小关系，又有连续可微的数学性质，同时， softmax 函数的输出向量是归一化的，即 $\sum_{j=1}^K \text{softmax}(\mathbf{z})_j = 1$

$$\text{softmax}(\mathbf{z})_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad j = 1, 2, \dots, K \quad (2.9)$$

综合起来，可以得到线性多分类模型

$$\hat{y} = \text{softmax}(w^T \mathbf{x} + \mathbf{b}) \quad (2.10)$$

3 多层感知机

3.1 基本思路

图 2 中最左边是线性多分类器，将 x 换成非线性函数 $\phi_i(x)$ ，则可以转化为一个简单的非线性多分类器（对应图 2 中间的模型）。进一步，对 x 作线性变换 wx 如果让非线性函数 $\phi_i(x)$ 也变成关于 wx 的函数，则该模型将变成一个 2 层感知机（对应图 2 最右边的模型）。




图 2 多层感知机基本思路

再进一步，将图 2 最右边模型的输入 x 作线性变换 wx ，并换成 $\phi_i(wx)$ 则可以得到一个 3 层的感知机。

重复以上操作，可以得到任意层数的感知机。

一般地，将 ϕ 记为激活函数 a ，

3.2 前向传播

根据线性多分类模型（感知机）(2.10)，很容易得到 2 层感知机的前向传播过程：

$$\hat{y} = \text{softmax}(\mathbf{w}_2^T a(\mathbf{w}_1^T x) + \mathbf{b}) \quad (3.1)$$

由此可以推广到 L 层感知机的前向传播过程：

$$\hat{y} = \text{softmax}(\mathbf{w}_L^T a(\mathbf{w}_{L-1}^T a(\mathbf{w}_{L-2}^T \dots a(\mathbf{w}_1^T x) \dots) + \mathbf{b}) + \mathbf{b}) \quad (3.2)$$

3.3 反向传播

如图 3 所示，假如现在要求损失函数 $\mathcal{L}$ 关于第 $l-1$ 层与第 l 层之间的权重 $W^{(l)}$ 的梯度 $\frac{\partial \mathcal{L}}{\partial W^{(l)}}$ 。

首先考虑损失函数 $\mathcal{L}$ 关于第 $l-1$ 层第 k 个激活函数与第 l 层第 i 个激活函数之间的权重 $W_{k,i}^{(l)}$ 的梯度 $\frac{\partial \mathcal{L}}{\partial W_{k,i}^{(l)}}$

$$\frac{\partial \mathcal{L}}{\partial W_{k,i}^{(l)}} = \frac{\partial \mathcal{L}}{\partial h_{l,i}} \frac{\partial h_{l,i}}{\partial \tilde{h}_{l,i}} \frac{\partial \tilde{h}_{l,i}}{\partial W_{k,i}^{(l)}} \quad (3.3)$$




图 3 反向传播

由于

$$h_{l,i} = a(\tilde{h}_{l,i}) \quad (3.4)$$

所以

$$\frac{\partial h_{l,i}}{\partial \tilde{h}_{l,i}} = a'(\tilde{h}_{l,i}) \quad (3.5)$$

由于

$$\tilde{h}_{l,i} = W_{k,i}^{(l)} h_{l-1,k} \quad (3.6)$$

所以

$$\frac{\partial \tilde{h}_{l,i}}{\partial W_{k,i}^{(l)}} = h_{l-1,k} \quad (3.7)$$

将 (3.5) 和 (3.6) 代入 (3.3), 得到

$$\frac{\partial \mathcal{L}}{\partial W_{k,i}^{(l)}} = \frac{\partial \mathcal{L}}{\partial h_{l,i}} a'(\tilde{h}_{l,i}) h_{l-1,k} \quad (3.8)$$

因此, 损失函数 $\mathcal{L}$ 关于第 $l-1$ 层与第 l 层之间的权重 $W^{(l)}$ 的梯度为

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \left(\mathbf{a}'(\mathbf{h}_l) \odot \frac{\partial \mathcal{L}}{\partial \mathbf{h}_l} \right) \mathbf{h}_{l-1}^T \quad (3.9)$$

下面再求损失函数 $\mathcal{L}$ 关于第 l 层输出 $\mathbf{h}_l$ 的梯度 $\frac{\partial \mathcal{L}}{\partial \mathbf{h}_l}$

先考虑损失函数 $\mathcal{L}$ 关于第 l 层第 i 个激活函数输出 $h_{l,i}$ 的梯度 $\frac{\partial \mathcal{L}}{\partial h_{l,i}}$

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial h_{l,i}} &= \sum_{j=1}^m \left(\frac{\partial \mathcal{L}}{\partial h_{l+1,j}} \frac{\partial h_{l+1,j}}{\partial \tilde{h}_{l+1,j}} \frac{\partial \tilde{h}_{l+1,j}}{\partial h_{l,i}} \right) \\
&= \sum_{j=1}^m \left(\frac{\partial \mathcal{L}}{\partial h_{l+1,j}} a'(\tilde{h}_{l+1,j}) W_{i,j}^{(l+1)} \right)
\end{aligned} \tag{3.10}$$

因此，损失函数 $\mathcal{L}$ 关于第 l 层输出 $\mathbf{h}_l$ 的梯度为

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}_l} = W^{(l+1)\top} \left(\mathbf{a}'(\mathbf{h}_{l+1}) \odot \frac{\partial \mathcal{L}}{\partial \mathbf{h}_{l+1}} \right) \tag{3.11}$$

反复利用 (3.9) 和 (3.11)，就可以求得损失函数关于所有权重的梯度，然后再利用梯度下降法，就可以更新权重参数，达到训练的效果。

4 支持向量机

基本思路：如图 4 所示，在空间中寻找一个超平面将两个类别分开，而且要位于两类样本点的“正中间”，即超平面要离两类样本点尽可能远，从而使得这个划分超平面对两类样本的局部扰动的容忍度较高（鲁棒性高）。




图 4 支持向量机基本思路

4.1 空间向量基础知识

4.1.1 超平面

在三维空间中，平面可以表示为

$$Ax + By + Cz + D = 0$$

其中, A, B, C, D 都是常数, $(A, B, C)^T$ 是平面的法向量。

推广到 d 维空间中, 超平面可以表示为

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (4.1)$$

其中, $\mathbf{x} \in \mathbb{R}^d$, $\mathbf{w} \in \mathbb{R}^d$ 是超平面的法向量, $b \in \mathbb{R}$ 是偏置。

4.1.2 点到超平面的距离

d 维空间中任意一点 $\mathbf{x} \in \mathbb{R}^T$ 到超平面 (4.1) 的距离为:

$$d = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|} \quad (4.2)$$

4.2 线性支持向量机

线性支持向量机又称为线性最大间隔分类器 (Linear Maximum Margin Classifier), 其本质是利用一个线性的超平面将两个类别分开, 并且使得两类样本点的间隔最大, 也就是使得该超平面到两类样本点的距离最大。

4.2.1 优化问题

假设一个样本数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$, 其中, $\mathbf{x}_i \in \mathbb{R}^n$ 是第 i 个样本的输入向量, $y_i \in \{-1, +1\}$ 是第 i 个样本的类别标签。类别标签 y_i 与样本输入向量 $\mathbf{x}_i$ 之间的关系为

$$\begin{cases} y_i = 1, & \text{if } \mathbf{x}_i \in \mathcal{C}_1 \\ y_i = -1, & \text{if } \mathbf{x}_i \in \mathcal{C}_2 \end{cases}$$

在基本思路的指导下, 假设所找到的划分超平面为

$$\mathbf{w}^T \mathbf{x} + b = 0 \quad (4.3)$$

其中, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{w} \in \mathbb{R}^n$

那么利用超平面进行决策的方法是:

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b > 0, & \text{if } y_i = 1 \\ \mathbf{w}^T \mathbf{x}_i + b < 0, & \text{if } y_i = -1 \end{cases} \quad (4.4)$$

距离划分超平面最近的点就被称为支持向量, 记为 $\mathbf{x}_s$ 两个异类支持向量所在的超平面被称为“间隔边界”。

关键步骤 4.1: 缩放变换

为了后面的计算方便，做以下缩放变换：

对超平面方程 (4.3) 两边同时乘一个系数 $\varsigma > 0$, 得到

$$(\varsigma \mathbf{w})^T \mathbf{x} + (\varsigma b) = 0 \quad (4.5)$$

令 $\mathbf{w}' = \varsigma \mathbf{w}$, $b' = \varsigma b$,

使得距离划分超平面最近的点 $\mathbf{x}_s$ 到超平面的距离均为 1, 即

$$\begin{cases} \mathbf{w}'^T \mathbf{x}_s + b' = 1, & \text{if } y_i = 1 \\ \mathbf{w}'^T \mathbf{x}_s + b' = -1, & \text{if } y_i = -1 \end{cases} \quad (4.6)$$

那么 (4.4) 变为

$$\begin{cases} \mathbf{w}'^T \mathbf{x}_i + b' \geq 1, & \text{if } y_i = 1 \\ \mathbf{w}'^T \mathbf{x}_i + b' \leq -1, & \text{if } y_i = -1 \end{cases} \quad (4.7)$$

在后面的推导中，将 $\mathbf{w}'$ 记为 $\mathbf{w}$, b' 记为 b 。

由 (4.7) 可知，对于任意样本点 $(\mathbf{x}_i, y_i)$, 都有

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \quad (4.8)$$




图 5 线性支持向量机示意图

如图 5 所示，根据点到超平面的距离公式 (4.2) 可知，两个异类支持向量到划分超平面的距离之和为

$$\begin{aligned}
l &= \frac{|\mathbf{w}^T \mathbf{x}_{s,c_1} + b|}{\|\mathbf{w}\|} + \frac{|\mathbf{w}^T \mathbf{x}_{s,c_2} + b|}{\|\mathbf{w}\|} \\
&= \frac{|1|}{\|\mathbf{w}\|} + \frac{|-1|}{\|\mathbf{w}\|} \\
&= \frac{2}{\|\mathbf{w}\|}
\end{aligned} \tag{4.9}$$

综合 (4.8) 和 (4.9)，前面的思路可以表述为以下优化问题

$$\begin{aligned}
\max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\
s.t. \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m
\end{aligned} \tag{4.10}$$

关键步骤 4.2: 优化问题转化

由于最大化 $\frac{1}{\|\mathbf{w}\|}$ 等价于最小化 $\|\mathbf{w}\|^2$
因此，优化问题 (4.10) 等价于以下优化问题：

$$\begin{aligned}
\min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\
s.t. \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m
\end{aligned} \tag{4.11}$$

这就是线性支持向量机的原始优化问题。

4.2.2 对偶问题

一种方法是可以直接利用梯度下降法等优化方法求解优化问题 (4.11)（原问题）。另一种方法是求解其对偶问题，这样会导出一些更好的性质。

下面使用拉格朗日乘子法求解优化问题 (4.11)。构造拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m \alpha_i [1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)] \tag{4.12}$$

其中， $\boldsymbol{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_m)^T$ 是拉格朗日乘子，且 $\alpha_i \geq 0, i = 1, 2, \dots, m$ 。展开得：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - \sum_{i=1}^m \alpha_i y_i b \tag{4.13}$$

所以其对偶函数为

$$g(\boldsymbol{\alpha}) = \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) \tag{4.14}$$

对 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 分别对 $\mathbf{w}$ 和 b 求偏导，并令其为 0，得：

$$\begin{cases} \frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = 0 \\ \frac{\partial L}{\partial b} = - \sum_{i=1}^m \alpha_i y_i = 0 \end{cases} \tag{4.15}$$

解得

$$\begin{cases} \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \\ \sum_{i=1}^m \alpha_i y_i = 0 \end{cases} \quad (4.16)$$

将 (4.16) 代入 (4.13), 得

$$\begin{aligned} g(\boldsymbol{\alpha}) &= \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}) \\ &= \frac{1}{2} \left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}_j \right) + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \alpha_i y_i \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}_j^T \right) \mathbf{x}_i - 0 \cdot b \\ &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{i=1}^m \alpha_i - \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \end{aligned} \quad (4.17)$$

注解：在 (4.17) 的推导中，

$$\left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}_j \right) = \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$$

当 $m = 2$ 时，就是下面这样展开

$$(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2)^T (a_1 \mathbf{x}_1) + a_2 \mathbf{x}^T = a_1^2 \mathbf{x}_1^T \mathbf{x}_1 + a_1 a_2 \mathbf{x}_1^T \mathbf{x}_2 + a_2 a_1 \mathbf{x}_2^T \mathbf{x}_1 + a_2^2 \mathbf{x}_2^T \mathbf{x}_2$$

关键步骤 4.3: 转化成对偶问题

根据对偶问题的定义，结合 (4.17)，优化问题 (4.11) 的对偶问题为

$$\max_{\boldsymbol{\alpha}} g(\boldsymbol{\alpha}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad (4.18)$$

$$s.t. \quad \begin{cases} \alpha_i \geq 0, & i = 1, 2, \dots, m \\ \sum_{i=1}^m \alpha_i y_i = 0 \end{cases} \quad (4.19)$$

4.2.3 模型求解与结果

在求解出最优拉格朗日乘子 $\boldsymbol{\alpha}^*$ 后，可以利用 (4.16) 求解出最优参数 $\mathbf{w}^*$

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i \quad (4.20)$$

考虑所有在间隔边界上的样本（即支持向量） $\mathbf{x}_s, y_s$ ，在理想情况下，他们全都被正

确分类，那么它们满足

$$\begin{cases} \mathbf{w}^T \mathbf{x}_s + b = 1 & \text{and } y_s = 1, & \text{if } \mathbf{x}_s \in \mathcal{C}_1 \\ \mathbf{w}^T \mathbf{x}_s + b = -1 & \text{and } y_s = -1, & \text{if } \mathbf{x}_s \in \mathcal{C}_2 \end{cases}$$

那么

$$y_s = \mathbf{w}^T \mathbf{x}_s + b$$

因此，可以求解出偏置 b^*

$$b^* = y_s - (\mathbf{w}^*)^T \mathbf{x}_s$$

显然，支持向量不止一个，记支持向量集合为 S , 支持向量的个数就为 $|S|$ ，那么可以得到 $|S|$ 个 b 的值。

为了提高模型的鲁棒性，可以取所有支持向量的平均值作为 b^*

$$\begin{aligned} b^* &= \frac{1}{|S|} \sum_{\mathbf{x}_s \in S} (y_s - (\mathbf{w}^*)^T \mathbf{x}_s) \\ &= \frac{1}{|S|} \sum_{\mathbf{x}_s \in S} (y_s - \sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x}_s) \end{aligned} \quad (4.21)$$

所以求得的决策边界为

$$(\mathbf{w}^*)^T \mathbf{x}_s + b^* = 0$$

代入 (4.20)，得其对偶形式

$$\sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x} + b^* = 0$$

那么，线性支持向量机分类器可以表示为：

$$f(\mathbf{x}) = \text{sign}((\mathbf{w}^*)^T \mathbf{x} + b^*) \quad (4.22)$$

代入 (4.20)，得其对偶形式

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x} + b^* \right) \quad (4.23)$$

关键步骤 4.4: KKT 条件

在求解优化问题 (4.11) 时，需要满足 KKT 条件：

$$\begin{cases} \alpha_i \geq 0, \\ y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 \geq 0, \\ \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0 \end{cases} \quad (4.24)$$

由最后 1 个条件（互补松弛条件）可知：当且仅当 $y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 = 0$ 时， $\alpha_i \neq 0$ ，即只有支持向量对应的拉格朗日乘子 α_i 才不等于 0，其他样本点对应的拉格朗日乘子均为 0。

因此，如果采用对偶形式 (4.23)，则其最终的线性支持向量机分类器只与支持向量（即间隔边界上的点）有关，而与其他样本点无关，可表示为：

$$f(\mathbf{x}) = \text{sign} \left(\sum_{\mathbf{x}_s \in S} \alpha_s^* y_s \mathbf{x}_s^T \mathbf{x} + b^* \right) \quad (4.25)$$

相比于 (4.23)，(4.25) 的计算量大大减小。

至此，线性支持向量机分类器的推导与求解完毕。

4.2.4 线性支持向量机分类器的分析

观察线性支持向量机分类器的对偶形式 (4.25) 可以发现：线性支持向量机分类器中有一项是支持向量与待分类样本点的内积 $\mathbf{x}_s^T \mathbf{x}$ ，这其实是衡量两个向量之间的相似度。若内积越大，则两个向量越相似。

4.2.5 软间隔支持向量机

在前面的推导中，一直是假设数据集是线性可分的，但在实际问题中，数据集往往是线性不可分的，即使是线性可分的，也很难断定找到的线性分类器并没有过拟合。为了缓解过拟合的问题，一个方法是允许支持向量机模型在少量训练样本上出错，也就是由前面的“硬间隔”（要求全部训练样本都不能出错）变成“软间隔”，如图 6 所示。




图 6 软间隔支持向量机示意图

软间隔支持向量机的原始优化问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m \\ & \xi_i \geq 0, \quad i = 1, \dots, m \end{aligned} \quad (4.26)$$

其中, ξ_i 是松弛变量, 表示第 i 个样本点违反约束条件的程度, $C > 0$ 是惩罚参数, 用于权衡间隔大小和违反约束条件的程度。

Lagrange 函数为

$$L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i [1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b)] - \sum_{i=1}^m \beta_i \xi_i \quad (4.27)$$

对偶函数就是

$$g(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \inf_{\mathbf{w}, b, \boldsymbol{\xi}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\beta}) \quad (4.28)$$

$$= \inf_{\mathbf{w}, b, \boldsymbol{\xi}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i + \sum_{i=1}^m \alpha_i [1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b)] - \sum_{i=1}^m \beta_i \xi_i \right\} \quad (4.29)$$

为了求出 Lagrange 函数的下界, 需要求解 Lagrange 函数关于 $\mathbf{w}, b, \boldsymbol{\xi}$ 的梯度:

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad (4.30)$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^m \alpha_i y_i \quad (4.31)$$

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i, \quad i = 1, 2, \dots, m \quad (4.32)$$

令它们都等于 0, 得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad (4.33)$$

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad (4.34)$$

$$C - \alpha_i - \beta_i = 0, \quad i = 1, 2, \dots, m \quad (4.35)$$

将以上结果代入 (4.28), 得

$$g(\boldsymbol{\alpha}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad (4.36)$$

注意: 这时的 $\boldsymbol{\beta}$ 已经被消去, 所以对偶函数只与 $\boldsymbol{\alpha}$ 有关。

因此, 软间隔支持向量机的对偶问题为

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & g(\boldsymbol{\alpha}) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m \\ & \beta_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned} \quad (4.37)$$

由于 $\beta_i = C - \alpha_i$ ，所以 $\beta_i \geq 0$ 等价于 $\alpha_i \leq C$ 。因此，软间隔支持向量机的对偶问题最终表达形式为

$$\begin{aligned} \max_{\alpha} \quad & g(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m \end{aligned} \quad (4.38)$$

下面通过对比“硬间隔支持向量机”和“软间隔支持向量机”来说明软间隔支持向量机的原理与推导公式。

硬间隔支持向量机	软间隔支持向量机
约束条件	约束条件
每个样本点 $(\mathbf{x}_i, y_i)$, $i = 1, 2, \dots, m$, 都要严格地分类正确, 即	对于每个样本点 $(\mathbf{x}_i, y_i)$, $i = 1, 2, \dots, m$, 引入松弛变量 $\xi_i \geq 0$, 使得约束条件变为
$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m$	$\begin{cases} y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ \xi_i > 0 \end{cases} \quad i = 1, \dots, m$
原问题	原问题
$\min_{\mathbf{w}, b} \quad \frac{1}{2} \ \mathbf{w}\ ^2$	$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_{i=1}^m \xi_i$
$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m$	$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m$
对偶问题	对偶问题
$\max_{\alpha} \quad \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$	$\max_{\alpha} \quad \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$
$\text{s.t.} \quad \alpha_i \geq 0, \quad i = 1, \dots, m$	$\text{s.t.} \quad \alpha_i \geq 0, \quad i = 1, \dots, m$
$\sum_{i=1}^m \alpha_i y_i = 0$	$\alpha_i \leq C, \quad i = 1, \dots, m$
所得分类器	所得分类器
$f(\mathbf{x}) = \text{sign} \left(\sum_{\mathbf{x}_s \in S} \alpha_s^* y_s \mathbf{x}_s^T \mathbf{x} + b^* \right)$	$\sum_{i=1}^m \alpha_i y_i = 0$
只有在间隔边界上的点（即支持向量）所对应的 $\alpha_s^* \neq 0$ 。	$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^m \alpha_i^* y_i \mathbf{x}_i^T \mathbf{x} + b^* \right) \quad (4.42)$
	只有在间隔边界内的点所对应的 $\alpha_i^* \neq 0$ 。

4.3 非线性支持向量机

在实际问题中，数据集往往是线性不可分的，可以考虑使用基函数 $\phi(\mathbf{x})$ 来替代原始输入向量 $\mathbf{x}$ ，将其映射到高维特征空间中，使得在高维特征空间中数据集是线性可分的，从而使用线性支持向量机进行分类。

4.3.1 非线性支持向量机的优化问题与求解

下面直接推导带有软间隔的非线性支持向量机。如果想要得到带有硬间隔的非线性支持向量机，只需将松弛变量 ξ_i 去掉即可。

软间隔的非线性支持向量机对应的优化问题是

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \quad (4.43)$$

$$s.t. \quad y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, m \quad (4.44)$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, m \quad (4.45)$$

其对偶问题为

$$\max_{\alpha} \quad \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \quad (4.46)$$

$$s.t. \quad \alpha_i \geq 0, \quad i = 1, \dots, m \quad (4.47)$$

$$\alpha_i \leq C, \quad i = 1, \dots, m \quad (4.48)$$

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad (4.49)$$

所得分类器

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^m \alpha_i^* y_i \phi(\mathbf{x}_i)^T \phi(\mathbf{x}) + b^* \right) \quad (4.50)$$

考虑到 $\phi(\mathbf{x}_i)^T \phi(\mathbf{x})$ 计算量比较大，引入核函数来简化计算。

定义核函数为

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \quad (4.51)$$

注解：核函数实际上是计算两个向量在高维特征空间中的内积，得到的是一个标量，利用这个标量来替代原来的高维向量内积，能够大大降低计算复杂度。

代入核函数 (4.51)，非线性支持向量机分类器可以表示为

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^m \alpha_i^* y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b^* \right) \quad (4.52)$$

4.3.2 常用核函数

常用核函数的表达式与其特点比较如表 1 所示：

表 1 常用核函数

名称	表达式	参数	特点
线性核 (Linear)	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	无	只能处理线性问题
多项式核 (Polynomial)	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	d	能处理非线性问题，但对参数 d 比较敏感
高斯核 (RBF)	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = e^{-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\sigma^2}}$	σ	处理高度非线性问题，表现最稳定
Sigmoid 核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^T \mathbf{x}_j + \theta)$	β, θ	能处理非线性问题，但对参数和数据分布敏感，性能不稳定

简而言之，线性核只适用于线性问题，而其他核函数都使用于非线性问题。

5 线性分类器的损失函数及其优化函数

5.1 常见线性分类器的损失函数

5.1.1 支持向量机的损失函数

硬间隔支持向量机的优化函数为

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2$$

如果允许有部分样本点分类错误，并且考虑这些被错误分类的样本点数带来的影响，这个影响可以利用 0/1 损失函数来衡量：

$$L_{0/1}(z) = \begin{cases} 0, & \text{if } z \geq 0 \\ 1, & \text{if } z < 0 \end{cases} \quad (5.1)$$

那么，优化函数可以写为

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad (5.2)$$

回顾软间隔支持向量机的优化问题：

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m \\ & \xi_i > 0, \quad i = 1, \dots, m \end{aligned}$$

不难发现，松弛变量 ξ_i 可以表示为：

$$\xi_i = \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.3)$$

定义 hinge 损失函数为：

$$L_{\text{hinge}}(z) = \max(0, 1 - z) \quad (5.4)$$

利用 hinge 损失函数, (5.3) 可以表示为：

$$\xi_i = L_{\text{hinge}}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.5)$$

将 (5.5) 代入软间隔支持向量机的优化函数，得到：

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{\text{hinge}}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.6)$$

5.1.2 logistics 回归的损失函数

logistics 回归中本质上就是采用了对数损失函数：

在 logistics 回归中，假设样本点 $(\mathbf{x}_i, y_i)$ ，则优化函数可以表示为

$$J(\mathbf{w}, b) = - \sum_{i=1}^m (\tilde{y}_i \ln(\sigma(\mathbf{w}^T \mathbf{x}_i + b)) + (1 - \tilde{y}_i) \ln(\sigma(\mathbf{w}^T \mathbf{x}_i + b))) + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (5.7)$$

其中， $\sigma(h) = \frac{1}{1+e^{-h}}$ 是 sigmoid 函数， $\tilde{y}_i \in \{0, 1\}$ 是样本点的标签， $\frac{\lambda}{2} \|\mathbf{w}\|^2$ 是正则化项。

定义 $y_i \in \{-1, 1\}$ ，它与 $\tilde{y}_i$ 的关系为

$$\begin{cases} y_i = 1, & \text{if } \tilde{y}_i = 1 \\ y_i = -1, & \text{if } \tilde{y}_i = 0 \end{cases} \quad (5.8)$$

并且引入对数损失函数：

$$L_{\log}(z) = \ln(1 + e^{-z}) \quad (5.9)$$

则 logistics 回归的优化函数 (5.7) 等价于

$$J(\mathbf{w}, b) = \sum_{i=1}^m \ln(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (5.10)$$

$$= \sum_{i=1}^m L_{\log}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) + \frac{\lambda}{2} \|\mathbf{w}\|^2 \quad (5.11)$$

5.1.3 常见损失函数总结

常见的损失函数总结如下：

- 0/1 损失函数：

$$L_{0/1}(z) = \begin{cases} 0, & z \geq 0 \\ 1, & z < 0 \end{cases} \quad (5.12)$$

梯度函数：不存在梯度。

- hinge 损失函数：

$$L_{hinge}(z) = \max(0, 1 - z) \quad (5.13)$$

梯度函数：

$$\frac{\partial L_{hinge}(z)}{\partial z} = \begin{cases} -1, & z < 1 \\ 0, & z \geq 1 \end{cases} \quad (5.14)$$

- 对数损失函数：

$$L_{log}(z) = \ln(1 + e^{-z}) \quad (5.15)$$

梯度函数：

$$\frac{\partial L_{log}(z)}{\partial z} = -\frac{1}{1 + e^z} \quad (5.16)$$

- 指数损失函数：

$$L_{exp}(z) = e^{-z} \quad (5.17)$$

梯度函数：

$$\frac{\partial L_{exp}(z)}{\partial z} = -e^{-z} \quad (5.18)$$

5.2 线性分类器的优化函数一般形式

由前面的优化函数 (5.2)，(5.6) 和 (5.10) 可以发现，分类器的优化函数具有以下共同形式：

$$\min_{\mathbf{w}, b} \quad \Omega(h) + C \sum_{i=1}^m L(y_i, h(\mathbf{x}_i)) \quad (5.19)$$

其中， h 为分类器的函数。

$\Omega(h)$ 可以理解为结构风险，描述模型本身的性质；也可以理解为正则化项，降低模型过拟合的风险。

$L(y_i, h(\mathbf{x}_i))$ 为经验风险，描述模型与训练数据的契合程度，可以取前文所介绍的各种损失函数。

C 是权重，用来平衡结构风险与经验风险在优化函数中的重要性。

5.2.1 常见优化函数总结

将常见的损失函数代入线性分类器的优化函数 (5.19)，得到常见的优化函数如下：

- 0/1 损失函数的优化函数：

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{0/1}(y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1) \quad (5.20)$$

梯度函数：不存在梯度。

- hinge 损失函数的优化函数：

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{hinge}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.21)$$

梯度函数：

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{w} + C \sum_{i=1}^m \begin{cases} -y_i \mathbf{x}_i, & y_i(\mathbf{w}^T \mathbf{x}_i + b) < 1 \\ 0, & otherwise \end{cases} \quad (5.22)$$

$$\frac{\partial J}{\partial b} = C \sum_{i=1}^m \begin{cases} -y_i, & y_i(\mathbf{w}^T \mathbf{x}_i + b) < 1 \\ 0, & otherwise \end{cases} \quad (5.23)$$

- 对数损失函数的优化函数：

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{log}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.24)$$

梯度函数：

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{w} + C \sum_{i=1}^m \frac{(-y_i \mathbf{x}_i)}{1 + e^{y_i(\mathbf{w}^T \mathbf{x}_i + b)}} \quad (5.25)$$

$$\frac{\partial J}{\partial b} = C \sum_{i=1}^m \frac{-y_i}{1 + e^{y_i(\mathbf{w}^T \mathbf{x}_i + b)}} \quad (5.26)$$

- 指数损失函数的优化函数：

$$J(\mathbf{w}, b) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m L_{exp}(y_i(\mathbf{w}^T \mathbf{x}_i + b)) \quad (5.27)$$

梯度函数：

$$\frac{\partial J}{\partial \mathbf{w}} = \mathbf{w} + C \sum_{i=1}^m (-y_i \mathbf{x}_i) e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)} \quad (5.28)$$

$$\frac{\partial J}{\partial b} = C \sum_{i=1}^m (-y_i) e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)} \quad (5.29)$$

6 训练方法与技巧

训练模型的一种常用方法是：梯度下降法。

6.1 梯度下降法

梯度下降法的基本思想是：沿着目标函数梯度的反方向更新参数，从而使目标函数值逐步减小，最终达到最小值。假设学习率为 η ，则利用梯度下降法更新任意参数 θ 的公式为：

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t) \quad (6.1)$$

如果只选取一个样本点来计算梯度，则称为随机梯度下降法（SGD）；如果选取全部样本点来计算梯度，则称为批量梯度下降法（BGD）；如果选取部分样本点来计算梯度，则称为小批量梯度下降法（MBGD）。

6.2 动量梯度下降法

为了避免陷入局部最优，并且加快收敛速率，可以在梯度下降法的基础上引入动量项。假设动量项为 $\mathbf{v}$ ，动量衰减率为 ρ ，则利用动量梯度下降法更新任意参数 θ 的公式为：

$$\mathbf{v}_t = \rho \mathbf{v}_{t-1} + \nabla f(\theta_{t-1}) \quad (6.2)$$

$$\theta_{t+1} = \theta_t - \eta \mathbf{v}_t \quad (6.3)$$

6.3 RMSProp

利用 RMSProp 更新任意参数 θ 的公式为：

$$\mathbf{s}_t = \rho \mathbf{s}_{t-1} + (1 - \rho) \|\nabla f(\theta_{t-1})\|^2 \quad (6.4)$$

$$\theta_{t+1} = \theta_t - \eta \nabla f(\theta_t) \oslash \sqrt{\mathbf{s}_t + \epsilon} \quad (6.5)$$

其中， $\oslash$ 是逐个元素除法， ϵ 是一个很小的常数，防止分母为 0。

6.4 Adam

Adam（Adaptive Moment Estimation）结合了动量法（Momentum）和 RMSProp 的思想，旨在通过计算梯度的一阶矩估计和二阶矩估计来调整每个参数的学习率，从而实现自适应的参数更新。

首先计算梯度的一阶矩估计（动量项）和二阶矩估计：

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla f(\theta_{t-1}) \quad (6.6)$$

$$\mathbf{s}_t = \beta_2 \mathbf{s}_{t-1} + (1 - \beta_2) \|\nabla f(\theta_{t-1})\|^2 \quad (6.7)$$

由于初始时刻的 $\mathbf{m}_0$ 和 $\mathbf{s}_0$ 均为 0，导致在前几次迭代中， $\mathbf{m}_t$ 和 $\mathbf{s}_t$ 会有偏差。为了纠正这种偏差，引入偏差修正：

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t} \quad (6.8)$$

$$\hat{\mathbf{s}}_t = \frac{\mathbf{s}_t}{1 - \beta_2^t} \quad (6.9)$$

最后，利用修正后的矩估计来更新参数：

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \hat{\mathbf{m}}_t \oslash \sqrt{\hat{\mathbf{s}}_t + \epsilon} \quad (6.10)$$

其中， $\oslash$ 是逐个元素除法， ϵ 是一个很小的常数，防止分母为 0。

综上，利用 Adam 更新任意参数 $\boldsymbol{\theta}$ 的公式为：

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \nabla f(\boldsymbol{\theta}_{t-1}) \quad (6.11)$$

$$\mathbf{s}_t = \beta_2 \mathbf{s}_{t-1} + (1 - \beta_2) \|\nabla f(\boldsymbol{\theta}_{t-1})\|^2 \quad (6.12)$$

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t} \quad (6.13)$$

$$\hat{\mathbf{s}}_t = \frac{\mathbf{s}_t}{1 - \beta_2^t} \quad (6.14)$$

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \hat{\mathbf{m}}_t \oslash \sqrt{\hat{\mathbf{s}}_t + \epsilon} \quad (6.15)$$

默认情况下，一般将参数设置为： $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ， $\epsilon = 10^{-8}$ ， $\eta = 0.001$ 。

特别地，当 $\beta_1 = 0$ 时，Adam 退化为 RMSProp；当 $\beta_2 = 0$ 时，Adam 退化为动量梯度下降法。

7 卷积神经网络

卷积神经网络（Convolutional Neural Network，CNN）是一种用于处理图像数据的神经网络。

卷积神经网络主要分为两部分，一部分为卷积部分，另一部分为全连接部分。

卷积部分主要用于提取图像中的特征，它由卷积核、归一化层、激活层和池化层组成。其中归一化层和池化层是可选的。

而全连接部分则用于分类，其结构与神经网络相同。

一层简单但完整的卷积神经网络结构如图 7 所示。

8 聚类分析

聚类分析（Clustering）是一种无监督学习方法，用于将数据集划分为几个子集，称为“簇”，使得每个簇内的数据点相似度高，而簇间的数据点相似度低。




图 7 一层简单但完整的卷积神经网络

8.1 K-Means

K-Means 是一种经典的无监督学习算法，用于将数据集划分为 K 个簇（clusters）。其目标是最小化簇内样本与簇中心之间的平方距离，属于原型（prototype-based）聚类方法。

8.1.1 问题定义

给定数据集：

$$X = \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}\}, \mathbf{x}^{(n)} \in \mathbb{R}^d$$

我们希望将数据划分为 K 个簇，并为每个簇找到一个中心（centroid）：

$$\boldsymbol{\mu}_k \in \mathbb{R}^d, k = 1, 2, \dots, K$$

K-Means 的优化目标是最小化总的簇内平方误差（Within-Cluster Sum of Squares, WCSS）：

$$J = \sum_{k=1}^K \sum_{n=1}^N \gamma_{nk} \|\mathbf{x}^{(n)} - \boldsymbol{\mu}_k\|^2 \quad (8.1)$$

其中， γ_{nk} 为簇指示变量，表示样本 $\mathbf{x}^{(n)}$ 是否属于簇 k 。

$$\gamma_{nk} = \begin{cases} 1, & \text{if } n \text{ belongs to cluster } k \\ 0, & \text{otherwise} \end{cases} \quad (8.2)$$

那么 $\gamma_{n1}, \gamma_{n2}, \dots, \gamma_{nK}$ 就构成一个独热向量，表示样本 $\mathbf{x}^{(n)}$ 属于哪一个簇。

$$\boldsymbol{\gamma}_n = [\gamma_{n1}, \gamma_{n2}, \dots, \gamma_{nK}]^T$$

8.1.2 算法思想

Step1: 簇分配 (Assignment Step) 将每个样本分配给最近的簇中心:

$$\gamma_{nk} = \begin{cases} 1, & k = \arg \min_j \|\mathbf{x}^{(n)} - \boldsymbol{\mu}_j\|^2 \\ 0, & \text{otherwise} \end{cases} \quad (8.3)$$

Step2: 更新簇中心 (Update Step) 根据新的簇分配, 更新簇中心, 其实就是求出每个簇内样本点的均值作为新的簇中心:

$$\boldsymbol{\mu}_k = \frac{\sum_{n=1}^N \gamma_{nk} \mathbf{x}^{(n)}}{\sum_{n=1}^N \gamma_{nk}} \quad (8.4)$$

8.1.3 算法流程

Algorithm 1 K-Means Algorithm

Require: Dataset $X = \{x^{(1)}, \dots, x^{(N)}\}$, number of clusters K

Ensure: Centroids $\{\mu_1, \dots, \mu_K\}$

- 1: Randomly initialize K centroids μ_k
- 2: **repeat**
- 3: **(Assignment Step)** For each sample $x^{(n)}$, determine its cluster label:

$$r_{nk} = \begin{cases} 1, & k = \arg \min_j \|x^{(n)} - \mu_j\|^2 \\ 0, & \text{otherwise} \end{cases}$$

- 4: **(Update Step)** Update each centroids:

$$\mu_k = \frac{\sum_{n=1}^N r_{nk} x^{(n)}}{\sum_{n=1}^N r_{nk}}$$

- 5: **until** Centroids stop changing or the objective function converges
-

9 隐变量模型

隐变量模型 (Latent Variable Model, LVM) 通过引入未观测的潜在变量来解释数据生成过程, 将复杂分布拆解为简单结构。

假设隐变量为 z ，而观测变量为 x ，则隐变量模型为：

$$p(x, z) = p(z|x)p(x) \quad (9.1)$$

$$p(x) = \sum_z p(x, z) \quad \text{if } z \text{ is discrete} \quad (9.2)$$

$$p(x) = \int_z p(x, z) dz \quad \text{if } z \text{ is continuous} \quad (9.3)$$

9.1 隐变量模型的训练

给定数据集 $\{\mathbf{x}_i\}_{i=1}^N$ ，如何训练隐变量模型 $p_\theta(\mathbf{x}, \mathbf{z})$

问题转化：

模型 $p_\theta(\mathbf{x}, \mathbf{z})$ 越好，则该模型与训练数据的拟合程度越高，说明要最大化数据样本的概率密度

$$p_\theta(\mathbf{x}) = \prod_{i=1}^N p_\theta(\mathbf{x}_i)$$

即

$$\max_{\theta} \prod_{i=1}^N p_\theta(\mathbf{x}_i)$$

取对数概率，得到

$$\max_{\theta} \sum_{i=1}^N \log p_\theta(\mathbf{x}_i)$$

将 $p_\theta(\mathbf{x}_i) = \int_{\mathbf{z}_i} p_\theta(\mathbf{x}_i, \mathbf{z}_i) dz_i$ 代入，得到

$$\max_{\theta} \sum_{i=1}^N \log \int_{\mathbf{z}_i} p_\theta(\mathbf{x}_i, \mathbf{z}_i) dz_i \quad (9.4)$$

由 (9.4) 可见，隐变量模型的训练难度主要在于很难写出 $p_\theta(\mathbf{x}_i)$ 的表达式，因为其中存在积分。

9.2 高斯混合模型

高斯混合模型（Gaussian Mixture Model, GMM）是由多个高斯分布组成的混合分布。

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k) \quad (9.5)$$

其中， π_k 是第 k 个高斯分布的权重， $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k)$ 是第 k 个高斯分布， $\boldsymbol{\mu}_k$ 是第 k 个高斯分布的均值， Σ_k 是第 k 个高斯分布的协方差矩阵。

补充说明： $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \Sigma)$ 表示高斯分布（又称为正态分布），其表达式为：

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right) \quad (9.6)$$

高斯混合模型可以写成隐变量模型的形式，下面给出具体的推导
假设 $\mathbf{z}$ 是一个独热向量

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_K \end{bmatrix}, \quad z_k = \{0, 1\}, \quad k = 1, \dots, K$$

用 $\mathbf{e}_k$ 表示第 k 个元素为 1，其余元素为 0 的独热向量。

对于 $\forall k, (k = 1, \dots, K)$, 在高斯混合模型中

1. 每一个高斯分布 $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k)$ 可以视为是条件分布 $p(\mathbf{x}|\mathbf{z} = \mathbf{e}_k)$
2. 权重 π_k 可视为先验概率 $p(\mathbf{z} = \mathbf{e}_k)$

即有：

$$p(\mathbf{x}|\mathbf{z} = \mathbf{e}_k) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k) \quad (9.7)$$

$$p(\mathbf{z} = \mathbf{e}_k) = \pi_k \quad (9.8)$$

注意：权重 π_k 对应一个类别分布，表示 $\mathbf{z}$ 属于第 k 类的概率，满足

$$0 < \pi_k < 1, \quad k = 1, \dots, K \quad (9.9)$$

$$\sum_{k=1}^K \pi_k = 1 \quad (9.10)$$

于是可以得到边缘分布：

$$\begin{aligned} p(\mathbf{x}) &= \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z}) \\ &= \sum_{k=1}^K p(\mathbf{x}, \mathbf{z} = \mathbf{e}_k) \\ &= \sum_{k=1}^K p(\mathbf{z} = \mathbf{e}_k) p(\mathbf{x}|\mathbf{z} = \mathbf{e}_k) \\ &= \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k) \end{aligned} \quad (9.11)$$

结合 (9.11), 后验概率 $p(\mathbf{z} = \mathbf{e}_k|\mathbf{x})$ 可以表示为：

$$\begin{aligned} p(\mathbf{z} = \mathbf{e}_k|\mathbf{x}) &= \frac{p(\mathbf{x}, \mathbf{z} = \mathbf{e}_k)}{p(\mathbf{x})} \\ &= \frac{\pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k)}{\sum_{i=1}^K \pi_i \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_i, \Sigma_i)} \end{aligned} \quad (9.12)$$

考虑到 $\mathbf{z}$ 是一个独热向量，(9.7) 和 (9.8) 可以写为更一般的形式

$$p(\mathbf{x}|\mathbf{z}) = \prod_{k=1}^K (\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k))^{z_k} \quad (9.13)$$

$$p(\mathbf{z}) = \prod_{k=1}^K \pi_k^{z_k} \quad (9.14)$$

利用 (9.13) 和 (9.14), 可以写出 $\mathbf{x}, \mathbf{z}$ 的联合概率分布, 即为隐变量模型

$$\begin{aligned} p(\mathbf{x}, \mathbf{z}) &= p(\mathbf{z})p(\mathbf{x}|\mathbf{z}) \\ &= \prod_{k=1}^K \pi_k^{z_k} \prod_{k=1}^K (\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k))^{z_k} \\ &= \prod_{k=1}^K (\pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k))^{z_k} \end{aligned} \quad (9.15)$$

对于一个数据集 $\{\mathbf{x}^{(i)}\}_{i=1}^N$, 假设每一个数据样本 $\mathbf{x}^{(i)}$ 之间是独立且同分布的, 则它们的联合概率分布为:

$$p(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}) = \prod_{i=1}^N p(\mathbf{x}^{(i)})$$

代入高斯混合模型的边缘分布 (9.11), 得到:

$$p(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}) = \prod_{i=1}^N \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}^{(i)}; \boldsymbol{\mu}_k, \Sigma_k) \quad (9.16)$$

对 (9.16) 取对数, 可得:

$$\begin{aligned} &\ln p(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}) \\ &= \sum_{i=1}^N \ln \left[\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}^{(i)}; \boldsymbol{\mu}_k, \Sigma_k) \right] \\ &= \sum_{i=1}^N \ln \sum_{k=1}^K \pi_k \left[\frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} (\mathbf{x}^{(i)} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x}^{(i)} - \boldsymbol{\mu}) \right) \right] \end{aligned} \quad (9.17)$$

9.3 EM 算法

隐变量模型的参数难以估计, 需要使用 EM 算法来训练。

EM 算法的基本思想是通过最大化似然函数在隐变量 $\mathbf{z}$ 上的期望, 从而更新模型的参数 θ 。

9.3.1 理论保证

首先将对数似然函数进行重新表示, 假设隐变量 $\mathbf{z}$ 的分布为 $q(\mathbf{z})$ 显然有 $\sum_{\mathbf{z}} q(\mathbf{z}) = 1$, 故

$$\ln p(\mathbf{x}; \theta) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln p(\mathbf{x}; \theta) \quad (9.18)$$

由条件概率的知识, 有:

$$p(\mathbf{x}; \theta) = \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{p(\mathbf{z}|\mathbf{x}; \theta)} \quad (9.19)$$

将 (9.19) 代入 (9.18), 得到

$$\begin{aligned} \ln p(\mathbf{x}; \theta) &= \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{p(\mathbf{z}|\mathbf{x}; \theta)} \\ &= \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta) q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \theta) q(\mathbf{z})} \\ &= \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta) q(\mathbf{z})}{q(\mathbf{z}) p(\mathbf{z}|\mathbf{x}; \theta)} \\ &= \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z})} + \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \theta)} \end{aligned}$$

即

$$\ln p(\mathbf{x}; \theta) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z})} + \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \theta)} \quad (9.20)$$

根据 KL 散度的知识, KL 散度用于衡量两个概率分布之间的距离, 如果两个分布越接近, 则 KL 散度越接近 0。

如果 $\mathbf{z}$ 是连续变量, 则 KL 散度为

$$KL(q||p) \triangleq \int_{\mathbf{z}} q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z})} d\mathbf{z} \quad (9.21)$$

如果 $\mathbf{z}$ 是离散变量, 则 KL 散度为

$$KL(q||p) \triangleq \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z})} \quad (9.22)$$

KL 散度具有非负性

$$KL(q||p) \geq 0$$

不难发现, (9.20) 的等号右边部分就是 KL 散度,

$$KL(q(\mathbf{z})||p(\mathbf{z}|\mathbf{x}; \theta)) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x}; \theta)} \geq 0 \quad (9.23)$$

将 (9.23) 代入 (9.20), 就可以得到对数似然函数的一个下界。

$$\ln p(\mathbf{x}; \theta) \geq \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z})} \quad (9.24)$$

为了方便，将下界记为 lower bound

$$\mathcal{L}(q, \theta) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z})} \quad (9.25)$$

利用 (9.25) 中的 lower bound 和 (9.23) 中的 KL 散度，可以将对数似然函数 (9.20) 进一步表示为

$$\ln p(\mathbf{x}; \theta) = \mathcal{L}(q, \theta) + KL(q(\mathbf{z}) || p(\mathbf{z}|\mathbf{x}; \theta)) \quad (9.26)$$

考虑一种特殊情况：当 $\mathbf{z}$ 的分布就是后验概率时，即

$$q(\mathbf{z}) = p(\mathbf{z}|\mathbf{x}; \theta) \quad (9.27)$$

时，KL 散度 $KL(q(\mathbf{z}) || p(\mathbf{z}|\mathbf{x}; \theta)) = 0$ ，这时 $\mathcal{L}(q, \theta)$ 可以取到最大值，即

$$\ln p(\mathbf{x}; \theta) = \mathcal{L}(q, \theta)$$

代入 (9.27)，

$$\begin{aligned} \ln p(\mathbf{x}; \theta) &= \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta), \theta) \\ &= \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{p(\mathbf{z}|\mathbf{x}; \theta)} \end{aligned} \quad (9.28)$$

在训练过程中，对于 t 时刻，我们的目标是使得 $\ln p(\mathbf{x}; \theta^{(t)})$ 最大，那么要尽可能找到接近于 $p(\mathbf{z}|\mathbf{x}; \theta^{(t)})$ 的分布 $q(\mathbf{z})$ ，从而使得 KL 散度最小。

KL 散度最小为 0，这时 $q(\mathbf{z}) = p(\mathbf{z}|\mathbf{x}; \theta^{(t)})$ ，又根据前面的推导 (9.28) 可知，

$$\begin{aligned} \ln p(\mathbf{x}; \theta^{(t)}) &= \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta^{(t)}) \\ &= \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta^{(t)})}{p(\mathbf{z}|\mathbf{x}; \theta^{(t)})} \end{aligned} \quad (9.29)$$

在 t 时刻，通过最大化对数似然函数的下界（lower bound）来更新模型参数 θ

$$\theta^{(t+1)} = \arg \max_{\theta} \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta) \quad (9.30)$$

因此

$$\mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta^{(t+1)}) \geq \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta^{(t)}) \quad (9.31)$$

结合 (9.29) 和 (9.31)

$$\begin{aligned} \ln p(\mathbf{x}; \theta^{(t)}) &= \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta^{(t)}) \\ &\leq \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta^{(t+1)}) \\ &\leq \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t+1)}), \theta^{(t+1)}) \\ &= \ln p(\mathbf{x}; \theta^{(t+1)}) \end{aligned}$$

从而可知每一步更新都能使得似然函数递增。

$$\ln p(\mathbf{x}; \theta^{(t)}) \leq \ln p(\mathbf{x}; \theta^{(t+1)}) \quad (9.32)$$

上面 (9.32) 证明了似然函数是递增的。下面可以很容易地利用此结论来证明 EM 算法的更新也是递增的。

注意到似然函数的下界 (lower bound) 可以写为

$$\begin{aligned} \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta) &= \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln \frac{p(\mathbf{x}, \mathbf{z}; \theta^{(t)})}{p(\mathbf{z}|\mathbf{x}; \theta^{(t)})} \\ &= \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln p(\mathbf{x}, \mathbf{z}; \theta^{(t)}) - \sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \end{aligned} \quad (9.33)$$

不难发现，似然函数的下界可以写成两个部分：

1. 第一个部分 $\sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln p(\mathbf{x}, \mathbf{z}; \theta^{(t)})$ ，这部分就等于 $\mathbb{E}_{p(\mathbf{z}|\mathbf{x}; \theta^{(t)})} [\ln p(\mathbf{x}, \mathbf{z}; \theta)]$;
2. 第二个部分 $\sum_{\mathbf{z}} p(\mathbf{z}|\mathbf{x}; \theta^{(t)}) \ln p(\mathbf{z}|\mathbf{x}; \theta^{(t)})$ 是常数。

记期望为

$$\mathcal{Q}(\theta, \theta^{(t)}) \triangleq \mathbb{E}_{p(\mathbf{z}|\mathbf{x}; \theta^{(t)})} [\ln p(\mathbf{x}, \mathbf{z}; \theta)] \quad (9.34)$$

EM 算法更新参数 θ

$$\theta^{(t+1)} = \arg \max_{\theta} \mathcal{Q}(\theta, \theta^{(t)}) \quad (9.35)$$

那么最大化期望与最大化似然函数下界是等价的：

$$\arg \max_{\theta} \mathcal{Q}(\theta, \theta^{(t)}) \Leftrightarrow \arg \max_{\theta} \mathcal{L}(p(\mathbf{z}|\mathbf{x}; \theta^{(t)}), \theta)$$

由于前面 (9.32) 已经证明了似然函数是递增的，故 EM 算法也是保证递增的。

注意：以上证明其实是针对单个样本 $\mathbf{x}$ 的，对于多个样本的数据集 $\{\mathbf{x}^{(i)}\}_{i=1}^N$ ，期望的计算变为：

$$\mathcal{Q}(\theta, \theta^{(t)}) \triangleq \frac{1}{N} \sum_{n=1}^N \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} [\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta)] \quad (9.36)$$

其余部分的计算不变。

显然，在多个样本的数据集上，EM 算法也是保证递增的。

9.3.2 EM 算法总结

EM 算法的流程可以总结为：

Algorithm 2 EM Algorithm

Require: Dataset $X = \mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}$, initial parameters $\theta^{(0)}$

Ensure: Estimated parameters θ

- 1: $t \leftarrow 0$
- 2: **repeat**
- 3: **E-step:** Compute the posterior distribution of latent variables:

$$p(\mathbf{z} \mid \mathbf{x}; \theta^{(t)})$$

Then compute either the lower bound

$$\mathcal{L}(p(\mathbf{z} \mid \mathbf{x}; \theta^{(t)}))$$

or the auxiliary function

$$\mathcal{Q}(\theta; \theta^{(t)}) = \frac{1}{N} \sum_{n=1}^N \mathbb{E}_{p(\mathbf{z}^{(n)} \mid \mathbf{x}^{(n)}; \theta^{(t)})} \left[\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) \right].$$

- 4: **M-step:** Update the parameters:

$$\theta^{(t+1)} = \arg \max_{\theta} \mathcal{Q}(\theta; \theta^{(t)})$$

or equivalently maximize the lower bound $\mathcal{L}$.

- 5: $t \leftarrow t + 1$
 - 6: **until** log-likelihood is converged
-

9.4 EM 算法训练高斯混合模型

回顾高斯混合模型 (9.5)

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k)$$

其联合分布在 (9.15) 中已给出:

$$p(\mathbf{x}, \mathbf{z}) = \prod_{k=1}^K (\pi_k \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_k, \Sigma_k))^{z_k}$$

9.4.1 E step

为了计算 $\mathcal{Q}(\theta, \theta^{(t)})$

$$\mathcal{Q}(\theta, \theta^{(t)}) \triangleq \frac{1}{N} \sum_{n=1}^N \mathbb{E}_{p(\mathbf{z}^{(n)} \mid \mathbf{x}^{(n)}; \theta^{(t)})} \left[\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) \right]$$

首先要计算后验概率 $p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})$ 和联合分布的对数 $\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta)$

计算后验概率

$$\begin{aligned} p(\mathbf{z}^{(n)} = \mathbf{e}_k | \mathbf{x}^{(n)}; \theta^{(t)}) &= \frac{p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)} = \mathbf{e}_k; \theta^{(t)})}{\sum_{i=1}^K p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)} = \mathbf{e}_i; \theta^{(t)})} \\ &= \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}^{(n)} | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{i=1}^K \pi_i^{(t)} \mathcal{N}(\mathbf{x}^{(n)} | \mu_i^{(t)}, \Sigma_i^{(t)})} \end{aligned} \quad (9.37)$$

将此定义为

$$\gamma_{nk}^{(t)} \triangleq \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{i=1}^K \pi_i^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_i^{(t)}, \Sigma_i^{(t)})} \quad (9.38)$$

计算联合分布的对数

$$\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) = \sum_{k=1}^K z_k \left[\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \mu_k^{(t)}, \Sigma_k^{(t)}) \right] \quad (9.39)$$

结合 (9.39), 可写出单个样本 $\mathbf{x}^{(n)}$ 的期望

$$\begin{aligned} &\mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} \left[\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) \right] \\ &= \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} \left[\sum_{k=1}^K z_k \left(\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \mu_k, \Sigma_k) \right) \right] \\ &= \sum_{k=1}^K \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} \left[z_k \left(\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \mu_k, \Sigma_k) \right) \right] \\ &= \sum_{k=1}^K \left(\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \mu_k, \Sigma_k) \right) \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} [z_k] \end{aligned} \quad (9.40)$$

根据 (9.37),

$$\mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} [z_k] = \sum_{j=1}^K z_j \frac{\pi_j^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{i=1}^K \pi_i^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_i^{(t)}, \Sigma_i^{(t)})} \quad (9.41)$$

注意到只有 $z_k = 1$, 其余的 $z_j = 0 (j \neq k, j = 1, \dots, K)$ 所以 (9.41) 可以进一步化简为:

$$\begin{aligned} \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} [z_k] &= \sum_{j=1}^K z_j \frac{\pi_j^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{i=1}^K \pi_i^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_i^{(t)}, \Sigma_i^{(t)})} \\ &= \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{i=1}^K \pi_i^{(t)} \mathcal{N}(\mathbf{x}^{(n)}; \mu_i^{(t)}, \Sigma_i^{(t)})} \\ &= \gamma_{nk}^{(t)} \end{aligned} \quad (9.42)$$

将 (9.42) 代入 (9.40) 中, 得到单个样本 $\mathbf{x}^{(n)}$ 的期望

$$\mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} \left[\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) \right] = \sum_{k=1}^K \gamma_{nk}^{(t)} \left(\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \mu_k, \Sigma_k) \right) \quad (9.43)$$

那么多个样本的期望便很容易计算了

$$\begin{aligned}\mathcal{Q}(\theta, \theta^{(t)}) &= \frac{1}{N} \sum_{n=1}^N \mathbb{E}_{p(\mathbf{z}^{(n)}|\mathbf{x}^{(n)}; \theta^{(t)})} \left[\ln p(\mathbf{x}^{(n)}, \mathbf{z}^{(n)}; \theta) \right] \\ &= \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk}^{(t)} \left(\ln \pi_k + \ln \mathcal{N}(\mathbf{x}^{(n)}; \boldsymbol{\mu}_k, \Sigma_k) \right)\end{aligned}\quad (9.44)$$

将高斯分布 (9.6) 代入 (9.44) 中, 可得

$$\mathcal{Q}(\theta, \theta^{(t)}) = \frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk}^{(t)} \left[\ln \pi_k - \frac{1}{2} \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k \right)^T \Sigma_k^{-1} \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k \right) - \frac{1}{2} \ln |\Sigma_k| \right] + C \quad (9.45)$$

9.4.2 M step

经过前面的 E step, 我们已经得到了多个样本的期望 $\mathcal{Q}(\theta, \theta^{(t)})$, 具体表达式如 (9.45) 所示, 现在要求使得这个期望最大的参数 $\boldsymbol{\mu}_k, \Sigma_k, \pi_k, k = 1, 2, \dots, K$ 。

由于 (9.45) 是一个连续可微的函数, 因此可以通过求偏导, 并令其为 0 来求解参数。

对 $\boldsymbol{\mu}_k$ 求偏导

$$\frac{\partial \mathcal{Q}(\theta, \theta^{(t)})}{\partial \boldsymbol{\mu}_k} = \frac{1}{N} \sum_{n=1}^N \gamma_{nk}^{(t)} \Sigma_k^{-1} \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k \right) \quad (9.46)$$

令其等于 0, 即

$$\begin{aligned}\frac{1}{N} \sum_{n=1}^N \gamma_{nk}^{(t)} \Sigma_k^{-1} \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k \right) &= 0 \\ \Rightarrow \sum_{n=1}^N \gamma_{nk}^{(t)} \Sigma_k^{-1} \mathbf{x}^{(n)} &= \left(\sum_{n=1}^N \gamma_{nk}^{(t)} \right) \Sigma_k^{-1} \boldsymbol{\mu}_k \\ \Rightarrow \sum_{n=1}^N \gamma_{nk}^{(t)} \mathbf{x}^{(n)} &= \left(\sum_{n=1}^N \gamma_{nk}^{(t)} \right) \boldsymbol{\mu}_k \\ \Rightarrow \boldsymbol{\mu}_k &= \frac{\sum_{n=1}^N \gamma_{nk}^{(t)} \mathbf{x}^{(n)}}{\sum_{n=1}^N \gamma_{nk}^{(t)}}\end{aligned}\quad (9.47)$$

由于 $\gamma_{nk}^{(t)}$ 是样本 $\mathbf{x}^{(n)}$ 属于第 k 类的概率, 说明:

1. 如果 $\gamma_{nk}^{(t)}$ 接近于 1, 则 $\mathbf{x}^{(n)}$ 有较大可能性属于第 k 类
2. 如果 $\gamma_{nk}^{(t)}$ 接近于 0, 则 $\mathbf{x}^{(n)}$ 有较小可能性属于第 k 类

所以, 令 $N_k \triangleq \sum_{n=1}^N \gamma_{nk}^{(t)}$, N_k 表示属于第 k 类的样本数量

利用 N_k , (9.46) 中的 $\boldsymbol{\mu}_k$ 便可以写为

$$\boldsymbol{\mu}_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk}^{(t)} \mathbf{x}^{(n)} \quad (9.48)$$

对 Σ_k 求偏导

$$\frac{\partial \mathcal{Q}(\theta, \theta^{(t)})}{\partial \Sigma_k} = \frac{1}{2N} \Sigma_k^{-1} \left[\sum_{n=1}^N \gamma_{nk}^{(t)} (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k) (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k)^T - \left(\sum_{n=1}^N \gamma_{nk}^{(t)} \right) \Sigma_k \right] \Sigma_k^{-1} \quad (9.49)$$

令其等于 0，即

$$\begin{aligned} & \frac{1}{2N} \Sigma_k^{-1} \left[\sum_{n=1}^N \gamma_{nk}^{(t)} (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k) (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k)^T - \left(\sum_{n=1}^N \gamma_{nk}^{(t)} \right) \Sigma_k \right] \Sigma_k^{-1} = 0 \\ \Rightarrow \Sigma_k &= \frac{\sum_{n=1}^N \gamma_{nk}^{(t)} (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k) (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k)^T}{\sum_{n=1}^N \gamma_{nk}^{(t)}} \end{aligned} \quad (9.50)$$

代入 $N_k \triangleq \sum_{n=1}^N \gamma_{nk}^{(t)}$ ，可得

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk}^{(t)} (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k) (\mathbf{x}^{(n)} - \boldsymbol{\mu}_k)^T \quad (9.51)$$

$$\pi_k = \frac{N_k}{N} \quad (9.52)$$

9.4.3 GMM 的 EM 算法总结

GMM 的 EM 算法总结如下：

Algorithm 3 EM Algorithm for Gaussian Mixture Models (GMM)

Require: Data $\{\mathbf{x}^{(n)}\}_{n=1}^N$, number of components K

Ensure: Estimated parameters $\{\pi_k, \boldsymbol{\mu}_k, \Sigma_k\}_{k=1}^K$

- 1: Initialize parameters $\pi_k^{(0)}, \boldsymbol{\mu}_k^{(0)}, \Sigma_k^{(0)}$
- 2: $t \leftarrow 0$
- 3: **repeat**
- 4: **E-step:** Compute responsibilities

$$\gamma_{nk}^{(t+1)} = \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}^{(n)} \mid \boldsymbol{\mu}_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(\mathbf{x}^{(n)} \mid \boldsymbol{\mu}_j^{(t)}, \Sigma_j^{(t)})}.$$

Compute the log-likelihood:

$$\log p(\mathbf{x} \mid \pi^{(t)}, \boldsymbol{\mu}^{(t)}, \Sigma^{(t)}) = \sum_{n=1}^N \log \left(\sum_{k=1}^K \pi_k^{(t)} \mathcal{N}(\mathbf{x}^{(n)} \mid \boldsymbol{\mu}_k^{(t)}, \Sigma_k^{(t)}) \right).$$

- 5: **M-step:** Update parameters using the responsibilities

$$N_k^{(t+1)} = \sum_{n=1}^N \gamma_{nk}^{(t+1)}.$$

$$\boldsymbol{\mu}_k^{(t+1)} = \frac{1}{N_k^{(t+1)}} \sum_{n=1}^N \gamma_{nk}^{(t+1)} \mathbf{x}^{(n)}.$$

$$\Sigma_k^{(t+1)} = \frac{1}{N_k^{(t+1)}} \sum_{n=1}^N \gamma_{nk}^{(t+1)} \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k^{(t+1)} \right) \left(\mathbf{x}^{(n)} - \boldsymbol{\mu}_k^{(t+1)} \right)^T.$$

$$\pi_k^{(t+1)} = \frac{N_k^{(t+1)}}{N}.$$

- 6: $t \leftarrow t + 1$
 - 7: **until** log-likelihood is converged
-

10 图表的插入

切记：“上表下图”，即表格的标题在其上方，图的标题在其下方

10.1 表格的插入

表格应具有三线表格式，因此常用 `booktabs` 宏包，其标准格式如表 2 所示。

表 2 标准三线表格

$D(\text{in})$	$P_u(\text{lbs})$	$u_u(\text{in})$	β	$G_f(\text{psi.in})$
5	269.8	0.000674	1.79	0.04089
10	421.0	0.001035	3.59	0.04089
20	640.2	0.001565	7.18	0.04089

10.2 图的插入

先把图片导入到 `figures` 文件夹，然后再按照以下代码插入到论文中。插入的图片如图 8 所示。



图 8 风景图

代码解释：

`[!h]` 是位置参数，告诉 LaTeX 希望图片放在哪：

- `h` (here): 尽量放在当前位置。
- `t` (top): 放在页面顶部。
- `b` (bottom): 放在页面底部。
- `p` (page of floats): 单独放在一个只包含浮动体的页面。
- `!` (override): 忽略 LaTeX 的部分限制，更强制地按照指定位置放。

`[!h]` 就是强烈要求放在目前位置。

附录 A 文件列表

文件名	功能描述
q1.m	问题一程序代码
q2.py	问题二程序代码
q3.c	问题三程序代码
q4.cpp	问题四程序代码

附录 B 代码

q1.m

```
1 disp("Hello World!")
```

q2.py

```
1 print("Hello World!")
```

q3.c

```
1 #include <stdio.h>
2
3 int main()
4 {
5     printf("Hello World!");
6     return 0;
7 }
```

q4.cpp

```
1 #include <bits/stdc++.h>
2 using namespace std;
3
4 int main()
5 {
6     cout << "Hello World!" << endl;
7     return 0;
8 }
```